

LAPORAN TEKNIS KOMPREHENSIF

DiabeSense: Sistem Skrining Risiko Diabetes Personal Berbasis Machine Learning

ID Tim Capstone Project : CC26-PSU357

Tema Capstone : Healthy Lives & Well-being

Nama/Judul Proyek : DiabeSense

List Anggota :

1. (CACC296D6Y1661) - (Iqbal Raihan Faturrahman R.)- (AI Engineer) - **[Aktif]**
2. (CACC296D6X1371) - (Muflichatur Rofiah)- (AI Engineer) - **[Aktif]**
3. (CDCC004D6Y0331) - (Muhammad Fakhri Imamul Huda)- (Data Science) - **[Aktif]**
4. (CDCC296D6X2402) - (Syafira Nurul Hanifa) - (Data Science) - **[Aktif]**
5. (CFCC296D6Y0353) - (Andra Pratama) - (Fullstack Web Developer) - **[Aktif]**
6. (CFCC296D6X2881) - (Nabilah Lianda Putri)- (Fullstack Web Developer) - **[Aktif]**

ABSTRAK

DiabeSense merupakan proyek capstone yang dikembangkan untuk membantu proses skrining awal risiko diabetes secara personal menggunakan pendekatan data science, machine learning, dan web application. Proyek ini dilatarbelakangi oleh tingginya prevalensi diabetes serta rendahnya kesadaran masyarakat terhadap deteksi dini. Dataset yang digunakan berasal dari BRFSS 2015 Diabetes Health Indicators yang memuat indikator kesehatan, gaya hidup, kondisi klinis, dan faktor sosial-ekonomi.

Tahapan proyek dimulai dari data gathering, data assessment, data cleaning, exploratory data analysis, feature engineering, pembangunan model machine learning, pengembangan API service, serta integrasi ke dalam aplikasi web. Pada fase Data Science, dilakukan analisis terhadap faktor risiko diabetes melalui lima pertanyaan bisnis utama, meliputi faktor risiko klinis, gaya hidup, demografi usia dan BMI, komorbiditas, serta faktor sosial-ekonomi. Hasil analisis menunjukkan bahwa faktor seperti GenHlth, HighBP, BMI, HighChol, Age, dan metabolic risk score memiliki hubungan kuat terhadap diabetes. Feature engineering dilakukan dengan membangun Age Group, Metabolic Risk Score, dan Lifestyle Risk Score.

Pada fase AI Engineer, model Multi-Layer Perceptron dikembangkan untuk memprediksi risiko diabetes dengan prioritas pada recall kelas positif karena konteks sistem adalah skrining kesehatan. Model kemudian disajikan melalui FastAPI ML Service. Pada fase Full Stack, aplikasi web dikembangkan menggunakan Next.js, Supabase, dan integrasi API untuk menyediakan skrining dasar maupun

komprehensif. Dashboard Streamlit juga dikembangkan untuk menampilkan insight analitik secara interaktif.

Hasil akhir proyek adalah sistem skrining diabetes berbasis machine learning yang terdiri dari dashboard analitik, model prediksi, API service, dan web application. Sistem ini tidak dimaksudkan sebagai alat diagnosis medis, melainkan sebagai alat bantu skrining awal dan edukasi risiko bagi pengguna.

Kata kunci: diabetes, skrining risiko, machine learning, BRFSS, Streamlit, FastAPI, [Next.js](#).

ABSTRACT

DiabeSense is a capstone project developed to support early personal diabetes risk screening using data science, machine learning, and web application technologies. The project is motivated by the increasing prevalence of diabetes and the lack of early detection awareness among the general public. The dataset used in this project is the BRFSS 2015 Diabetes Health Indicators dataset, which includes health indicators, lifestyle factors, clinical conditions, and socioeconomic variables.

The project workflow includes data gathering, data assessment, data cleaning, exploratory data analysis, feature engineering, machine learning model development, API service development, and web application integration. In the Data Science phase, five business questions were analyzed, covering clinical risk factors, lifestyle behavior, age and BMI demographics, clinical comorbidities, and socioeconomic factors. The analysis showed that GenHlth, HighBP, BMI, HighChol, Age, and metabolic risk score were strongly associated with diabetes. Feature engineering was performed by creating Age Group, Metabolic Risk Score, and Lifestyle Risk Score.

In the AI Engineer phase, a Multi-Layer Perceptron model was developed to predict diabetes risk, with recall for the positive class prioritized due to the health screening context. The model was then deployed as a FastAPI ML Service. In the Full Stack phase, the web application was developed using Next.js, Supabase, and API integration to support both basic and comprehensive screening modes. An interactive Streamlit dashboard was also developed to present analytical insights.

The final output of this project is a machine learning-based diabetes screening system consisting of an analytics dashboard, prediction model, API service, and web application. The system is not intended to replace medical diagnosis but serves as an early screening and risk awareness tool for users.

Keywords: diabetes, risk screening, machine learning, BRFSS, Streamlit, FastAPI, [Next.js](#).

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Diabetes merupakan salah satu penyakit kronis yang terus mengalami peningkatan secara global. Penyakit ini dapat menyebabkan berbagai komplikasi serius seperti penyakit jantung, stroke, gagal ginjal, gangguan penglihatan, dan amputasi ekstremitas bawah. Salah satu tantangan utama dalam pengendalian diabetes adalah keterlambatan deteksi dini. Banyak individu tidak menyadari bahwa dirinya memiliki risiko diabetes sampai gejala atau komplikasi mulai muncul.

Di Indonesia, diabetes juga menjadi permasalahan kesehatan masyarakat yang signifikan. Peningkatan prevalensi diabetes berkaitan dengan perubahan pola hidup, meningkatnya obesitas, rendahnya aktivitas fisik, pola makan tidak sehat, serta hambatan akses pelayanan kesehatan. Kondisi ini menunjukkan bahwa deteksi dini dan edukasi risiko sangat penting untuk membantu masyarakat memahami kondisi kesehatannya sebelum berkembang menjadi komplikasi yang lebih serius.

Dalam konteks pengembangan sistem berbasis data, dataset BRFSS 2015 Diabetes Health Indicators digunakan sebagai sumber data utama. Dataset ini berasal dari survei kesehatan masyarakat yang memuat berbagai indikator klinis, perilaku hidup, dan sosial-ekonomi. Meskipun data BRFSS berasal dari Amerika Serikat, dataset ini tetap relevan sebagai proxy untuk mempelajari pola faktor risiko diabetes karena mencakup variabel yang umum digunakan dalam skrining risiko diabetes, seperti tekanan darah tinggi, kolesterol tinggi, BMI, riwayat penyakit jantung, aktivitas fisik, usia, dan pendapatan.

Berdasarkan permasalahan tersebut, proyek DiabeSense dikembangkan sebagai sistem skrining risiko diabetes personal berbasis machine learning. Sistem ini dirancang untuk membantu pengguna memperoleh estimasi risiko diabetes secara cepat dan mudah melalui aplikasi web. Selain itu, proyek ini juga menyediakan dashboard analitik untuk menampilkan insight berbasis data mengenai faktor risiko diabetes.

1.2 Rumusan Masalah

Rumusan masalah dalam proyek ini adalah sebagai berikut:

1. Faktor risiko klinis, demografis, gaya hidup, dan sosial-ekonomi apa yang paling berkorelasi dengan diabetes berdasarkan data BRFSS 2015?
2. Bagaimana membangun model machine learning yang dapat melakukan skrining risiko diabetes dengan prioritas recall tinggi?
3. Bagaimana mengintegrasikan model machine learning ke dalam web application yang dapat digunakan oleh pengguna umum?
4. Bagaimana menyajikan insight hasil analisis data secara interaktif melalui dashboard Streamlit?
5. Bagaimana menyediakan dua mode skrining, yaitu skrining dasar untuk guest dan skrining komprehensif untuk pengguna yang login?

1.3 Tujuan Proyek

Tujuan proyek DiabeSense adalah:

1. Menganalisis indikator kesehatan dari dataset BRFSS 2015 untuk mengidentifikasi faktor risiko utama diabetes.
2. Melakukan data wrangling, exploratory data analysis, feature engineering, dan feature reduction untuk menghasilkan dataset siap modeling.
3. Mengembangkan dashboard Streamlit untuk menampilkan insight utama terkait risiko diabetes.
4. Membangun model machine learning berbasis Multi-Layer Perceptron untuk skrining risiko diabetes.
5. Mengoptimalkan model dengan prioritas recall kelas positif agar sesuai dengan konteks skrining kesehatan.
6. Mengembangkan REST API berbasis FastAPI untuk menyajikan model sebagai layanan prediksi.
7. Mengembangkan web application berbasis Next.js yang mengintegrasikan ML service dan dapat digunakan oleh pengguna umum.
8. Menyediakan penjelasan risiko yang mudah dipahami pengguna melalui integrasi Gemini API atau fallback explanation.

1.4 Manfaat Proyek

Manfaat proyek ini dapat dilihat dari tiga sisi utama.

Bagi pengguna akhir, DiabeSense dapat membantu meningkatkan kesadaran terhadap risiko diabetes melalui skrining awal yang mudah diakses. Pengguna dapat mengetahui estimasi risiko berdasarkan informasi kesehatan dasar dan memperoleh rekomendasi awal untuk pemeriksaan lebih lanjut.

Bagi pengembangan sistem kesehatan digital, proyek ini memberikan contoh implementasi sistem skrining berbasis machine learning yang menggabungkan analitik data, model prediksi, API service, dan aplikasi web. Sistem ini dapat menjadi prototipe awal untuk pengembangan layanan kesehatan preventif berbasis digital.

Bagi aspek akademis dan teknis, proyek ini memberikan pembelajaran end-to-end mengenai data science pipeline, feature engineering, machine learning model development, deployment API, dan pengembangan full stack web application.

1.5 Ruang Lingkup

Ruang lingkup proyek ini meliputi:

1. Dataset yang digunakan adalah BRFSS 2015 Diabetes Health Indicators.
2. Dataset awal berisi 70.692 observasi dan 22 kolom.
3. Target prediksi adalah Diabetes_binary, dengan nilai 0 untuk tidak diabetes dan 1 untuk diabetes/prediabetes.


4. Sistem hanya digunakan untuk skrining awal, bukan diagnosis medis.
5. Fitur yang digunakan merupakan fitur klinis, gaya hidup, demografis, dan sosial-ekonomi tanpa pemeriksaan laboratorium seperti HbA1c atau gula darah puasa.
6. Model machine learning yang dikembangkan berfokus pada recall kelas positif.
7. Dashboard analitik dikembangkan menggunakan Streamlit dan Plotly.
8. ML service dikembangkan menggunakan FastAPI.
9. Web application dikembangkan menggunakan Next.js, Supabase, dan integrasi API.
10. Sistem akhir terdiri dari tiga komponen utama: Data Science Dashboard, ML Service, dan Web Application.

1.6 Arsitektur Sistem Keseluruhan


Arsitektur sistem DiabeSense terdiri dari tiga lapisan utama, yaitu frontend, backend/API route, dan ML service. Pengguna berinteraksi melalui web application berbasis Next.js. Data input dari pengguna dikirim ke API route yang berperan sebagai backend proxy. API route kemudian meneruskan request ke FastAPI ML Service yang menjalankan model MLP untuk menghasilkan probabilitas risiko diabetes.

Alur sistem dapat dijelaskan sebagai berikut:


1. Pengguna mengisi form skrining pada aplikasi web.
2. Frontend Next.js mengirimkan data ke API route.
3. API route melakukan validasi, autentikasi jika diperlukan, dan meneruskan data ke FastAPI ML Service.
4. FastAPI memproses input, mengisi fitur yang hilang dengan median jika menggunakan mode basic, melakukan scaling, dan menjalankan model prediksi.
5. Model menghasilkan probabilitas risiko diabetes.
6. Sistem mengonversi probabilitas menjadi kategori risiko rendah, sedang, atau tinggi.
7. Endpoint explain menghasilkan penjelasan risiko menggunakan Gemini API atau fallback text.
8. Hasil prediksi dikirim kembali ke frontend dan ditampilkan kepada pengguna.



Gambar 1. Arsitektur Komponen Frontend Next.js



Gambar 2. Next.js API Routes



Gambar 3. Arsitektur Supabase Auth

1.7 Metodologi Pengerjaan

Metodologi pengerjaan proyek dibagi berdasarkan tiga learning path utama:

1. **Data Science Phase**
Tim Data Science bertanggung jawab melakukan data gathering, data assessment, data cleaning, EDA, feature engineering, feature reduction, serta pengembangan dashboard Streamlit.
2. **AI Engineer Phase**
Tim AI Engineer bertanggung jawab mengembangkan model machine learning, melakukan data splitting, scaling, baseline modeling, pengembangan MLP, threshold optimization, evaluasi final, ekspor artefak model, dan deployment ML service.
3. **Full Stack Phase**
Tim Full Stack bertanggung jawab membangun web application, sistem autentikasi, form skrining, integrasi API, halaman hasil, riwayat skrining, reminder, dan deployment aplikasi.

Tabel 1. Metodologi Pengerjaan dan Pembagian Peran

Minggu	AI Engineer	Data Science	Fullstack Dev
1	Setup TensorFlow & Colab, studi arsitektur model, finalisasi project plan	Pengumpulan dataset, data assessment awal, identifikasi missing values	Setup React + Vite, Express.js backend, desain mockup UI
2	Terima clean dataset dari DS, mulai eksperimen model, implementasi Functional API	Data wrangling & cleaning, EDA lengkap, buat Data Dictionary	Bangun form skrining, halaman hasil prediksi, struktur API endpoint

Minggu	AI Engineer	Data Science	Fullstack Dev
3	Finalisasi & evaluasi model, ekspor .keras, bangun FastAPI endpoint	Visualisasi explanatory, mulai bangun Streamlit, feature engineering	Integrasi frontend – FastAPI, tampilkan hasil prediksi, Axios networking
4	Integrasi GenAI API, TensorBoard logging, testing API end-to-end	Finalisasi dashboard, deploy ke Streamlit Cloud, A/B Testing (opsional)	Integrasi database PostgreSQL, riwayat skrining user, link ke dashboard Streamlit
5	Dokumentasi notebook, finalisasi kode inference, bug fixing	Laporan teknis (PDF), review insight & kesimpulan, bug fixing	Responsive layout final, deployment (Vercel/Netlify), testing end-to-end
6	Review akhir, persiapan presentasi, finalisasi dokumentasi, pengumpulan project		

BAB 2

PROBLEM DISCOVERY & PEMAHAMAN DATA

2.1 Sumber Dataset

Dataset yang digunakan adalah BRFSS 2015 Diabetes Health Indicators. Dataset ini berasal dari Behavioral Risk Factor Surveillance System yang dikumpulkan oleh CDC dan tersedia secara publik melalui Kaggle. Dataset ini berisi indikator kesehatan yang dapat digunakan untuk menganalisis hubungan antara faktor klinis, perilaku hidup, kondisi demografis, dan diabetes.

Tabel 2. Ringkasan dataset:

Atribut	Nilai
Nama dataset	BRFSS 2015 Diabetes Health Indicators
Sumber	Kaggle / CDC BRFSS
Jumlah baris awal	70.692
Jumlah kolom awal	22
Target	Diabetes_binary
Missing values	0
Duplikat	5.858 baris
Dataset setelah deduplikasi	64.834 baris
Format data	Numerik, biner, ordinal, kontinu

Dataset yang digunakan dalam proyek ini sudah memiliki target biner sehingga sesuai untuk pengembangan model klasifikasi risiko diabetes.

2.2 Deskripsi Fitur Dataset

Fitur yang digunakan dalam dataset final mencakup aspek klinis, gaya hidup, demografis, dan sosial-ekonomi.

Tabel 3. fitur utama dataset

No	Nama Fitur	Jenis	Rentang Nilai	Deskripsi
----	------------	-------	---------------	-----------

1	HighBP	Biner	0–1	Riwayat tekanan darah tinggi
2	HighChol	Biner	0–1	Riwayat kolesterol tinggi
3	BMI	Kontinu	Numerik	Body Mass Index
4	Smoker	Biner	0–1	Pernah merokok minimal 100 batang
5	Stroke	Biner	0–1	Riwayat stroke
6	HeartDiseaseorAttack	Biner	0–1	Riwayat penyakit jantung atau serangan jantung
7	PhysActivity	Biner	0–1	Aktivitas fisik dalam 30 hari terakhir
8	Veggies	Biner	0–1	Konsumsi sayuran rutin
9	HvyAlcoholConsump	Biner	0–1	Konsumsi alkohol berat
10	GenHlth	Ordinal	1–5	Penilaian kesehatan umum
11	MentHlth	Kontinu	0–30	Jumlah hari kesehatan mental buruk
12	PhysHlth	Kontinu	0–30	Jumlah hari kesehatan fisik buruk
13	DiffWalk	Biner	0–1	Kesulitan berjalan atau naik tangga
14	Age	Ordinal	1–13	Kelompok usia BRFSS
15	Income	Ordinal	1–8	Tingkat pendapatan
16	NoDocbcCost	Biner	0–1	Tidak pergi ke dokter karena biaya
17	Age_group	Engineered	0–3 atau label	Kelompok usia hasil feature engineering
18	metabolic_risk_score	Engineered	0–4	Jumlah komorbiditas metabolik
19	lifestyle_risk_score	Engineered	0–3	Skor gaya hidup berisiko
20	Diabetes_binary	Target	0–1	Status diabetes

2.3 Business Questions

Tim Data Science mendefinisikan lima pertanyaan bisnis utama:

1. Q1: Faktor Risiko Utama
Dari indikator kesehatan yang digunakan, faktor mana yang paling berkorelasi dengan diabetes?

2. Q2: Gaya Hidup
Apakah individu yang tidak aktif secara fisik dan jarang mengonsumsi sayuran memiliki prevalensi diabetes lebih tinggi?
3. Q3: Demografis Usia dan BMI
Bagaimana distribusi prevalensi diabetes berdasarkan kelompok usia dan kategori BMI?
4. Q4: Komorbiditas Klinis
Seberapa besar pengaruh akumulasi komorbiditas terhadap probabilitas diabetes?
5. Q5: Sosial-Ekonomi
Apakah pendapatan rendah dan hambatan biaya layanan kesehatan berkorelasi dengan prevalensi diabetes yang lebih tinggi?

BAB 3

DATA SCIENCE: DATA PREPARATION & ANALISIS

3.1 Data Wrangling

3.1.1 Gathering Data

Tahap gathering dilakukan dengan mengambil dataset BRFSS 2015 Diabetes Health Indicators dari sumber publik. Dataset dimuat menggunakan pandas dan diperiksa secara awal untuk mengetahui jumlah baris, jumlah kolom, struktur fitur, serta target prediksi.

(70692, 22)

	Diabetes_binary	HighBP	HighChol	CholCheck	BMI	Smoker	Stroke	HeartDiseaseorAttack	PhysActivity	Fruits	Veggies	HvyAlcoholConsump
0	0.0	1.0	0.0	1.0	26.0	0.0	0.0	0.0	1.0	0.0	1.0	0.0
1	0.0	1.0	1.0	1.0	26.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0
2	0.0	0.0	0.0	1.0	26.0	0.0	0.0	0.0	1.0	1.0	1.0	0.0
3	0.0	1.0	1.0	1.0	28.0	1.0	0.0	0.0	1.0	1.0	1.0	0.0
4	0.0	0.0	0.0	1.0	29.0	1.0	0.0	0.0	1.0	1.0	1.0	0.0

Gambar 4. Ringkasan Data yang ditampilkan

3.1.2 Assessing Data

Pada tahap assessing, dilakukan pemeriksaan struktur dataset, tipe data, missing values, duplicate rows, serta validitas nilai unik pada setiap kolom. Hasil assessing menunjukkan bahwa dataset tidak memiliki missing values pada seluruh kolom. Namun, ditemukan 5.858 baris duplikat yang kemudian dipertimbangkan pada tahap cleaning.

Hasil assessing:

- 1) Dataset awal: 70.692 baris $\times$ 22 kolom
- 2) Missing values: 0
- 3) Duplikat: 5.858 baris
- 4) Sebagian besar fitur merupakan biner, ordinal, atau numerik kontinu
- 5) Target menggunakan format biner

3.1.3 Cleaning Data

Cleaning data dilakukan untuk memastikan dataset siap dianalisis dan digunakan pada tahap modeling. Langkah cleaning meliputi:

1. Menghapus baris duplikat.
2. Mengonversi tipe data biner dan ordinal menjadi integer.
3. Memilih fitur yang relevan berdasarkan business question dan kebutuhan modeling.
4. Memastikan tidak terdapat missing values.

5. Memastikan target tidak masuk ke dalam fitur training.
6. Menyimpan dataset final modeling.

0

Diabetes_binary	int64	HvyAlcoholConsump	int64
HighBP	int64	AnyHealthcare	float64
HighChol	int64	NoDocbcCost	int64
CholCheck	float64	GenHlth	float64
BMI	float64	MentHlth	float64
Smoker	int64	PhysHlth	float64
Stroke	int64	DiffWalk	int64
HeartDiseaseorAttack	int64	Sex	float64
PhysActivity	int64	Age	int64
Fruits	int64	Education	float64
Veggies	int64	Income	int64

Gambar 5. Tipe Data setelah Cleaning

Tabel 4. Dataset Final

Tahap	Jumlah Baris	Jumlah Kolom
Raw Dataset	70.692	22
Setelah data Cleaning	70.692	22
Dataset final modeling	64.834	20

Dataset final disimpan sebagai `clean_diabetes_modeling_ready.csv`.

3.2 Exploratory Data Analysis


3.2.1 Q1: Analisis Faktor Risiko Utama

Analisis korelasi Pearson dilakukan untuk mengukur hubungan antara fitur numerik dengan target `Diabetes_binary`. Hasil analisis menunjukkan bahwa fitur dengan korelasi tertinggi terhadap diabetes adalah `GenHlth`, `HighBP`, `BMI`, `HighChol`, dan `Age`.

Tabel 5. Analisis Faktor Risiko Utama

Rank	Fitur	Korelasi	Interpretasi
1	GenHlth	0,4076	Kesehatan umum subjektif
2	HighBP	0,3815	Hipertensi
3	BMI	0,2934	Body Mass Index
4	HighChol	0,2892	Kolesterol tinggi
5	Age	0,2787	Kelompok usia

Temuan ini menunjukkan bahwa faktor klinis mendominasi hubungan terhadap diabetes. GenHlth menjadi fitur tunggal paling kuat, yang menunjukkan bahwa persepsi kesehatan umum seseorang berkaitan erat dengan risiko diabetes. HighBP dan HighChol juga menunjukkan bahwa komorbiditas metabolik berperan penting dalam risiko diabetes.



Gambar 6. Grafik bar chart korelasi fitur terhadap Diabetes_binary.


3.2.2 Q2: Analisis Gaya Hidup

Analisis gaya hidup dilakukan menggunakan fitur PhysActivity, Veggies, Smoker, HvyAlcoholConsump, dan lifestyle_risk_score. Hasil analisis menunjukkan bahwa prevalensi diabetes cenderung meningkat seiring bertambahnya lifestyle risk score.

Tabel 6. Distribusi lifestyle risk score pada dataset final:

Lifestyle Risk Score	Jumlah Responden
0	19.092
1	27.668
2	14.625
3	3.449

Pola ini menunjukkan bahwa akumulasi gaya hidup tidak sehat berkaitan dengan peningkatan prevalensi diabetes. Aktivitas fisik dan konsumsi sayuran rutin berperan sebagai faktor protektif, sedangkan merokok dan konsumsi alkohol berat dapat meningkatkan risiko.



Gambar 7. grafik distribusi lifestyle risk score dan grafik prevalensi diabetes


3.2.3 Q3: Analisis Demografis Usia dan BMI

Analisis demografis dilakukan dengan mengelompokkan usia dan BMI untuk melihat pola prevalensi diabetes. Hasil heatmap menunjukkan bahwa prevalensi diabetes meningkat seiring bertambahnya usia dan meningkatnya kategori BMI.

Temuan utama:

- 1) Kelompok usia muda dengan BMI normal memiliki prevalensi diabetes paling rendah.
- 2) Kelompok usia lanjut dengan obesitas tingkat tinggi memiliki prevalensi diabetes paling tinggi.
- 3) Kombinasi usia tua dan obesitas menunjukkan pola risiko yang sangat kuat.

Temuan ini mendukung pentingnya personalisasi pesan risiko berdasarkan usia dan BMI.



Gambar 8. heatmap prevalensi diabetes berdasarkan Age Group dan BMI Category.

3.2.4 Q4: Analisis Komorbiditas Klinis

Untuk menganalisis akumulasi komorbiditas, dibuat fitur `metabolic_risk_score` yang merupakan jumlah dari HighBP, HighChol, HeartDiseaseorAttack, dan Stroke.

Formula:

$$\text{metabolic_risk_score} = \text{HighBP} + \text{HighChol} + \text{HeartDiseaseorAttack} + \text{Stroke}$$

Hasil analisis menunjukkan peningkatan prevalensi diabetes yang sangat konsisten seiring bertambahnya jumlah komorbiditas:


Tabel 7. Prevalensi Diabetes berdasarkan Komorbiditas

Jumlah Komorbiditas	Prevalensi Diabetes
0	19,09%
1	46,19%
2	69,45%
3	77,97%
4	84,02%

Tabel 8. Distribusi metabolic risk score

Metabolic Risk Score	Jumlah Responden
0	15.899
1	20.037
2	20.493
3	7.005
4	1.400

Temuan ini menunjukkan bahwa akumulasi komorbiditas klinis memiliki hubungan yang sangat kuat terhadap diabetes. Individu dengan empat komorbiditas memiliki prevalensi diabetes lebih dari 84%.



Gambar 9. Grafik line chart atau bar chart prevalensi diabetes berdasarkan metabolic risk score.

3.2.5 Q5: Analisis Sosial-Ekonomi


Analisis sosial-ekonomi dilakukan menggunakan Income dan NoDocbcCost. Hasil analisis menunjukkan bahwa kelompok dengan pendapatan rendah cenderung memiliki prevalensi diabetes lebih tinggi dibandingkan kelompok dengan pendapatan tinggi.

Tabel 9. Prevalensi Diabetes berdasarkan Income

Income Level	Prevalensi Diabetes
1	65,99%
2	68,61%
3	64,21%
4	60,89%
5	56,23%
6	51,43%
7	46,08%
8	34,85%

Terdapat gap sebesar 31,14 poin persentase antara kelompok pendapatan rendah dan tinggi. Selain itu, hambatan biaya kesehatan juga berkaitan dengan prevalensi diabetes yang lebih tinggi. Temuan

ini menunjukkan bahwa diabetes tidak hanya dipengaruhi oleh faktor klinis dan gaya hidup, tetapi juga oleh determinan sosial-ekonomi.



Gambar 10. Grafik prevalensi diabetes berdasarkan Income dan NoDocbcCost.

3.3 Feature Engineering

3.3.1 Age Group

Fitur Age pada BRFSS merupakan kategori ordinal. Untuk memudahkan interpretasi visualisasi, fitur ini dikonversi menjadi Age Group. Pengelompokan usia membantu dashboard menampilkan segmentasi risiko secara lebih mudah dipahami pengguna.

3.3.2 Metabolic Risk Score

Fitur metabolic_risk_score dibuat untuk merepresentasikan akumulasi komorbiditas klinis. Fitur ini menggabungkan HighBP, HighChol, HeartDiseaseorAttack, dan Stroke.

Fitur ini penting karena hasil EDA menunjukkan bahwa akumulasi komorbiditas lebih informatif dibandingkan hanya melihat fitur tunggal.

3.3.3 Lifestyle Risk Score

Fitur lifestyle_risk_score dibuat untuk merepresentasikan akumulasi perilaku hidup tidak sehat. Fitur ini dihitung dari aktivitas fisik, konsumsi sayuran, kebiasaan merokok, dan konsumsi alkohol berat.

Formula:

$$\text{lifestyle_risk_score} = (1 - \text{PhysActivity}) + (1 - \text{Veggies}) + \text{Smoker} + \text{HvyAlcoholConsump}$$

Fitur ini membantu menangkap pola risiko gaya hidup secara kumulatif.

3.4 Output Dataset Data Science

Tim Data Science menghasilkan dataset final yang siap digunakan untuk modeling, yaitu:

`clean_diabetes_modeling_ready.csv`

Dataset ini memiliki:

- 1) 64.834 baris
- 2) 20 kolom
- 3) 19 fitur input
- 4) 1 target
- 5) Tidak terdapat missing values
- 6) Sudah melalui proses deduplikasi
- 7) Sudah memiliki fitur engineered
- 8) Seluruh fitur sudah dalam format numerik

Dataset ini kemudian diserahkan ke tim AI Engineer untuk proses modeling.

3.5 Dashboard Streamlit: DiabeSense Analytics

Dashboard Streamlit dikembangkan untuk menampilkan insight hasil analisis secara interaktif. Dashboard ini dibangun menggunakan Streamlit, pandas, dan Plotly.

Struktur dashboard terdiri dari lima halaman utama:

1. Overview
2. Risk Factors
3. Metabolic Risk
4. Lifestyle Analysis
5. Socioeconomic Analysis

3.5.1 Halaman Overview

Halaman Overview menampilkan ringkasan dataset, metrik utama, distribusi diabetes, serta executive summary. Metrik utama yang ditampilkan meliputi total responden, jumlah kasus diabetes, jumlah non-diabetes, dan prevalensi diabetes dalam dataset.

3.5.2 Halaman Risk Factors

Halaman Risk Factors menampilkan grafik korelasi fitur utama terhadap Diabetes_binary. Fitur yang ditampilkan meliputi GenHlth, HighBP, BMI, HighChol, Age, dan DiffWalk.

3.5.3 Halaman Metabolic Risk

Halaman Metabolic Risk menampilkan hubungan antara metabolic risk score dan prevalensi diabetes. Halaman ini menjadi salah satu insight terkuat karena menunjukkan kenaikan prevalensi yang konsisten dari 19,09% pada skor 0 menjadi 84,02% pada skor 4.

3.5.4 Halaman Lifestyle Analysis

Halaman Lifestyle Analysis menampilkan distribusi lifestyle risk score dan hubungan antara lifestyle risk score dengan prevalensi diabetes. Halaman ini menunjukkan bahwa gaya hidup tidak sehat berkaitan dengan peningkatan risiko diabetes.

3.5.5 Halaman Socioeconomic Analysis

Halaman Socioeconomic Analysis menampilkan hubungan Income dan NoDocbcCost terhadap diabetes. Halaman ini menunjukkan bahwa faktor ekonomi dan akses layanan kesehatan juga berperan dalam risiko diabetes.


BAB 4

AI ENGINEER: MODEL DEVELOPMENT & ML SERVICE

4.1 Pemilihan Dataset dan Preprocessing

Model machine learning dikembangkan menggunakan dataset final dari tim Data Science, yaitu `clean_diabetes_modeling_ready.csv`. Dataset ini telah melalui proses cleaning, deduplikasi, feature engineering, dan siap digunakan untuk modeling.

Pada tahap awal, dataset dimuat dan dipisahkan menjadi fitur input dan target. Target yang digunakan adalah `Diabetes_binary`.



Gambar 11. Distribusi fitur numerik dan ordinal pada dataset diabetes.

4.2 Identifikasi Fitur Redundant

Beberapa fitur engineered bersifat turunan deterministik dari fitur lain, seperti `metabolic_risk_score`, `lifestyle_risk_score`, dan `age_group`. Pada tahap modeling, fitur-fitur ini dapat dipertimbangkan untuk dihapus apabila model menggunakan fitur aslinya agar tidak terjadi redundancy.

Setelah analisis terhadap fitur-fitur dalam dataset, ditemukan tiga fitur hasil rekayasa (engineered features) yang bersifat turunan deterministik dari fitur asli:

- 1) Metabolic_risk_score: turunan dari BMI, HighBP, HighChol, Stroke, HeartDiseaseorAttack
- 2) Lifestyle_risk_score: turunan dari Smoker, PhysActivity, HvyAlcoholConsump, Fruits, Veggies
- 3) Age_group: transformasi ordinal dari kolom Age

Keputusan final: Ketiga fitur engineered tersebut dihapus dari feature set training model MLP. dengan alasan:

1. Redundansi informasi

Model MLP memiliki kemampuan untuk mempelajari kombinasi non-linear dari fitur asli secara mandiri. Memasukkan fitur turunan yang deterministik berarti memberikan informasi yang sama dua kali, sehingga berpotensi memperbesar bobot fitur-fitur tersebut secara tidak proporsional.

2. Konsistensi deployment

Pada saat inferensi via API, input pengguna berupa nilai fitur asli (HighBP, BMI, dsb.), bukan skor turunan. Menghapus fitur ini dari training memastikan pipeline preprocessing produksi lebih sederhana.

3. Kelengkapan baseline comparison

Baseline model (Logistic Regression, Random Forest) dan model MLP menggunakan feature set yang identik, sehingga perbandingan performa bersifat *fair*.

Feature set final yang digunakan untuk training terdiri dari [NILAI] fitur asli.

4.3 Strategi Metrik Evaluasi

Karena DiabeSense digunakan untuk skrining kesehatan, metrik utama yang diprioritaskan adalah recall kelas positif. False negative dalam konteks skrining diabetes memiliki konsekuensi lebih serius karena pengguna yang berisiko dapat tidak terdeteksi. Oleh karena itu, recall menjadi prioritas dibandingkan accuracy semata.

Metrik yang digunakan:

- 1) Recall
- 2) Precision
- 3) F1-score
- 4) ROC-AUC
- 5) MAE probabilitas

Target performa:

- 1) Recall kelas positif $\geq 0,80$
- 2) ROC-AUC $\geq 0,80$

4.4 Data Splitting dan Scaling

Dataset dibagi menjadi train, validation, dan test set. Test set dipisahkan sejak awal sebagai holdout set murni dan tidak digunakan dalam proses training maupun threshold tuning.

Pembagian data:

- 1) Train: 60%
- 2) Validation: 20%
- 3) Test: 20%

Scaling dilakukan menggunakan StandardScaler. Scaler hanya di-fit pada data training untuk menghindari data leakage, kemudian digunakan untuk mentransformasi data validation dan test.

4.5 Baseline Models

Sebelum membangun model MLP, dibuat baseline model sebagai pembandingan. Model baseline yang digunakan adalah Logistic Regression dan Random Forest. Baseline ini membantu mengevaluasi apakah model MLP memberikan peningkatan performa dibandingkan pendekatan tradisional.

Dua model baseline dilatih dan dievaluasi pada validation set menggunakan feature set yang sama dengan model MLP. Logistic Regression dilatih dengan parameter `class_weight='balanced'` untuk menangani ketidakseimbangan kelas. Random Forest dilatih dengan `class_weight='balanced'` dan `n_estimators=100`. Hasil baseline ini digunakan sebagai acuan perbandingan untuk mengevaluasi apakah model MLP memberikan peningkatan performa yang bermakna, terutama pada metrik recall dan ROC-AUC.

- 1) Recall
- 2) Precision
- 3) F1-score
- 4) ROC-AUC

4.6 Arsitektur Model MLP

Model final dikembangkan menggunakan Multi-Layer Perceptron berbasis TensorFlow/Keras. Arsitektur model terdiri dari input layer, beberapa hidden layer dengan aktivasi ReLU, Batch Normalization, Dropout, dan output layer dengan aktivasi sigmoid.

Arsitektur umum:

- 1) Input layer: sesuai jumlah fitur
- 2) Hidden layer 1: Dense 64, ReLU, BatchNorm, Dropout
- 3) Hidden layer 2: Dense 32, ReLU, BatchNorm, Dropout

- 4) Hidden layer 3: Dense 16, ReLU
- 5) Output layer: Dense 1, Sigmoid

Output model berupa probabilitas risiko diabetes.

4.7 Training Model

Model dilatih menggunakan binary crossentropy sebagai loss function dan Adam optimizer. Early stopping diterapkan untuk menghindari overfitting. Selain itu, recall dipantau selama training karena recall merupakan metrik utama dalam konteks skrining.

Model MLP dilatih selama maksimal 100 epoch menggunakan `binary_crossentropy` sebagai loss function dan `Adam` optimizer dengan learning rate default. `EarlyStopping` diterapkan dengan `patience=10` memantau `val_recall` agar training berhenti otomatis ketika performa pada validation set tidak membaik.


4.8 Optimasi Threshold

Threshold klasifikasi tidak hanya menggunakan nilai default 0,50. Tim AI melakukan threshold optimization pada validation set untuk mencari threshold yang memenuhi target recall dengan precision yang tetap wajar.

Threshold final yang digunakan adalah:

$$\text{Threshold} = 0,45$$

Threshold ini dipilih karena mampu memenuhi target recall kelas positif dalam konteks skrining kesehatan.



... === KOMPARASI THRESHOLD (pada VALIDATION set) ===				
Threshold	Recall	Precision	F1	ROC-AUC
0.5	0.798	0.725	0.760	0.811
0.45	0.839	0.711	0.769	0.811
0.4	0.877	0.695	0.775	0.811
0.35	0.908	0.676	0.775	0.811
0.3	0.930	0.654	0.768	0.811

Gambar 12. Komparasi Threshold pada Validation Set

4.9 Evaluasi Final Model

Evaluasi final dilakukan pada test set (14.139 sampel, 20% data) yang telah dipisahkan sejak awal dan tidak pernah digunakan selama proses training maupun threshold tuning. Model MLP dengan threshold 0,45 dievaluasi pada data ini untuk mendapatkan estimasi performa yang tidak bias.

Tabel 10. Hasil Evaluasi Model MLP Final (Test Set, Threshold = 0,45)

Metrik	Nilai	Target	Status
Recall (kelas positif)	0,807	$\geq 0,80$	✓ Terpenuhi
Precision (kelas positif)	0,380	—	—
F1-Score (kelas positif)	0,516	—	—
ROC-AUC	0,877	$\geq 0,80$	✓ Terpenuhi
MAE Probabilitas	0,292	—	—

Tabel 11. Confusion Matrix (Test Set)

	Prediksi: Sehat (0)	Prediksi: Berisiko (1)
Aktual: Sehat (0)	TN = 9.474	FP = 2.653
Aktual: Berisiko (1)	FN = 389	TP = 1.623

Model MLP dengan threshold 0,45 berhasil memenuhi target recall kelas positif sebesar **0,807** pada test set, menunjukkan bahwa model mampu mendeteksi 80,7% pengguna berisiko diabetes. Jumlah

false negative sebesar 389 sampel mengindikasikan 19,3% kasus berisiko yang tidak terdeteksi — angka ini dapat diterima dalam konteks skrining awal berbasis kuesioner tanpa fitur laboratorium klinis, di mana tujuan utama adalah menyaring kandidat untuk pemeriksaan lanjutan, bukan mendiagnosis secara definitif.

Jumlah false positive sebesar 2.653 merefleksikan konsekuensi dari prioritas recall: sejumlah pengguna sehat akan diklasifikasikan sebagai berisiko. Dalam konteks aplikasi, hal ini ditangani dengan menyertakan rekomendasi konsultasi dokter sebagai tindak lanjut, bukan mengklaim diagnosis.

Tabel 12. Perbandingan Performa Ketiga Model (Test Set)

Model	Recall	Precision	F1-Score	ROC-AUC
Logistic Regression	0,793	0,413	0,543	0,886
Random Forest	0,321	0,749	0,450	0,869
MLP (threshold = 0,45)	0,807	0,380	0,516	0,877

MLP mengungguli kedua baseline pada metrik prioritas utama: *recall* (0,807 vs 0,793 LR, vs 0,321 RF). Random Forest memiliki precision tertinggi namun recall yang sangat rendah (0,321), menjadikannya tidak cocok untuk konteks skrining. Logistic Regression menghasilkan recall yang kompetitif, namun MLP dengan threshold yang dioptimasi memberikan sensitivitas yang lebih baik terhadap kasus berisiko dengan ROC-AUC yang kuat di angka 0,877.

4.10 Persiapan Mode Skrining Dasar

DiabeSense menyediakan dua mode skrining:

1. Skrining Dasar
2. Skrining Komprehensif

Pada skrining dasar, pengguna hanya mengisi tujuh fitur utama yang mudah dijawab:

- 1) Age
- 2) BMI
- 3) HighBP
- 4) GenHlth
- 5) PhysActivity

- 6) DiffWalk
- 7) Smoker

Fitur lain yang tidak diisi akan diimputasi menggunakan median dari training set. Strategi ini memungkinkan sistem digunakan oleh guest tanpa mewajibkan input terlalu banyak.

4.11 Ekspor Artefak Model

Artefak model yang diekspor untuk deployment meliputi:

- 1) Model Keras
- 2) StandardScaler
- 3) Feature order
- 4) Median values
- 5) Basic features
- 6) Threshold

Tabel 13. Artefak Model

Artefak	Deskripsi
diabetesense_model.keras	Model MLP final
scaler.pkl	StandardScaler dari training set
feature_order.json	Urutan fitur input
medians.json	Nilai median untuk imputasi basic mode
basic_features.json	Daftar fitur skrining dasar
threshold.txt	Threshold klasifikasi

4.12 FastAPI ML Service

ML service dikembangkan menggunakan FastAPI. Service ini bertugas menerima input dari backend/frontend, memproses data, menjalankan model, dan mengembalikan hasil prediksi berupa probabilitas risiko dan kategori risiko.

Endpoint utama:

- 1) GET /
- 2) GET /health
- 3) GET /docs
- 4) POST /predict/basic
- 5) POST /predict/comprehensive

6) POST /explain

Endpoint /explain digunakan untuk menghasilkan penjelasan risiko menggunakan Gemini API atau fallback explanation jika API key tidak tersedia.

BAB 5

FULL STACK: WEB APPLICATION

5.1 Tech Stack dan Struktur Proyek


Web application DiabeSense dikembangkan menggunakan Next.js, React, Tailwind CSS, Supabase, dan integrasi API. Next.js digunakan sebagai framework utama untuk frontend dan API route. Supabase digunakan untuk autentikasi pengguna dan penyimpanan data.

Tech stack:

- 1) Next.js
- 2) React
- 3) Tailwind CSS
- 4) Supabase
- 5) React Hook Form
- 6) Zod
- 7) Framer Motion
- 8) Lucide React
- 9) Recharts

5.2 Halaman Utama

Halaman utama berfungsi sebagai landing page sekaligus dashboard ringkasan. Untuk pengguna yang belum login, halaman menampilkan hero section, penjelasan fitur, dan CTA untuk melakukan skrining. Untuk pengguna yang sudah login, halaman dapat menampilkan ringkasan hasil skrining dan informasi personal.



Gambar 13. Halaman Landing page sebelum login



Gambar 14. Halaman landing page setelah login

5.3 Autentikasi

Sistem autentikasi menggunakan Supabase Auth. Pengguna dapat melakukan login dan register. Token JWT digunakan untuk membedakan akses antara guest dan user login, terutama pada skrining komprehensif.

5.4 Halaman Skrining

Halaman skrining menggunakan form multi-step untuk memudahkan pengguna mengisi data kesehatan. Terdapat dua mode skrining:

1. Skrining Dasar: dapat digunakan guest dan user login.
2. Skrining Komprehensif: hanya untuk user login.

Form menggunakan validasi input untuk memastikan data yang dikirim sesuai range dan format yang diharapkan.

5.5 API Routes

Next.js API Routes digunakan sebagai backend proxy antara frontend dan ML service. API route mengirim data input ke FastAPI ML Service dan menerima hasil prediksi. Dengan pendekatan ini, URL ML service tidak langsung terekspos ke frontend.

5.6 Halaman Hasil Skrining

Halaman hasil menampilkan:

- 1) Probabilitas risiko diabetes
- 2) Kategori risiko rendah/sedang/tinggi
- 3) Penjelasan risiko
- 4) Disclaimer medis
- 5) Tombol untuk menyimpan hasil atau melakukan skrining ulang

Disclaimer medis wajib ditampilkan karena sistem bukan alat diagnosis.

5.7 Halaman Riwayat Skrining

Halaman riwayat digunakan untuk menampilkan hasil skrining yang pernah dilakukan pengguna. Fitur ini membantu pengguna memantau perkembangan risiko dari waktu ke waktu.

5.8 Halaman Profil

Halaman profil menampilkan informasi pengguna dan data terkait skrining. Profil juga dapat digunakan untuk pre-fill form skrining agar pengguna tidak perlu mengisi ulang data yang sama.

5.9 Halaman Reminder

Halaman reminder memungkinkan pengguna membuat pengingat skrining berikutnya. Fitur ini mendukung upaya pencegahan dan monitoring berkala.

BAB 6

INTEGRASI & PENGUJIAN SISTEM

6.1 Alur Integrasi End-to-End

Alur integrasi sistem dimulai dari input pengguna pada web application. Data dikirim ke Next.js API route, kemudian diteruskan ke FastAPI ML Service. FastAPI memproses input, melakukan scaling, menjalankan model MLP, dan mengembalikan probabilitas risiko. Jika diperlukan, sistem juga memanggil endpoint explain untuk menghasilkan penjelasan risiko. Hasil akhir kemudian ditampilkan pada halaman hasil skrining.


6.2 Pengujian ML Service

Pengujian ML service dilakukan untuk memastikan endpoint prediksi berjalan dengan benar. Smoke test digunakan untuk mengirim contoh input dan memeriksa apakah output memiliki format yang sesuai.

6.3 Pengujian API via Swagger UI

Swagger UI digunakan untuk menguji endpoint FastAPI secara langsung. Endpoint yang diuji meliputi:

- 1) `/predict/basic`
- 2) `/predict/comprehensive`
- 3) `/explain`



Gambar 15. Pengujian API via Swagger UI

6.4 Pengujian Frontend

Pengujian frontend dilakukan dengan menjalankan alur skrining dari awal hingga akhir. Skenario pengujian meliputi:

1. Pengguna memilih mode skrining.
2. Pengguna mengisi form.
3. Sistem mengirim data ke API route.
4. Hasil prediksi ditampilkan.
5. Pengguna dapat menyimpan hasil atau melakukan skrining ulang.

6.5 Pengujian Validasi Input

Validasi input dilakukan untuk mencegah data kosong atau nilai di luar range. Jika input tidak valid, sistem menampilkan pesan error agar pengguna dapat memperbaiki isian.

BAB 7

DEPLOYMENT

7.1 Deployment ML Service

ML service direncanakan atau telah di-deploy menggunakan Hugging Face Spaces dengan Docker. Service berjalan pada port 7860 dan menyediakan endpoint prediksi serta dokumentasi Swagger.


7.2 Deployment Dashboard Streamlit

Dashboard Streamlit dikembangkan untuk menampilkan hasil analisis Data Science. Deployment dilakukan menggunakan Streamlit Cloud dengan repository GitHub yang berisi:

- 1) app.py
- 2) requirements.txt
- 3) dataset final
- 4) file pendukung visualisasi

Agar deployment berjalan stabil, `requirements.txt` minimal memuat:


- 1) streamlit
- 2) pandas
- 3) plotly



Gambar 16. Dashboard Analitik.

7.3 Deployment Web Application

Web application Next.js dapat di-deploy ke Vercel atau platform hosting sejenis. Deployment ini memungkinkan pengguna mengakses fitur skrining secara online.



Gambar 17. Web application dan screenshot build success. Bisa diakses melalui:

<https://diabesense-capstone-project.vercel.app/>

BAB 8

HASIL & PEMBAHASAN

8.1 Ringkasan Temuan Data Science

Hasil analisis Data Science menghasilkan lima temuan utama:

1. Faktor klinis mendominasi risiko diabetes.
GenHlth, HighBP, BMI, HighChol, dan Age merupakan fitur individu dengan korelasi tertinggi terhadap Diabetes_binary.
2. Akumulasi komorbiditas lebih informatif daripada faktor tunggal.
Metabolic Risk Score menunjukkan pola kenaikan prevalensi diabetes yang sangat kuat, dari 19,09% pada skor 0 hingga 84,02% pada skor 4.
3. Gaya hidup berperan dalam risiko diabetes.
Lifestyle Risk Score menunjukkan bahwa semakin banyak perilaku hidup berisiko, semakin tinggi prevalensi diabetes.
4. Usia dan BMI menunjukkan interaksi risiko.
Kelompok usia lanjut dengan BMI tinggi memiliki prevalensi diabetes tertinggi.
5. Faktor sosial-ekonomi berperan penting.
Kelompok dengan pendapatan rendah memiliki prevalensi diabetes lebih tinggi dibandingkan kelompok berpendapatan tinggi.

8.2 Performa Model Final

Model final menggunakan pendekatan MLP dengan threshold 0,45. Dalam konteks skrining kesehatan, recall kelas positif menjadi prioritas utama karena false negative dapat menyebabkan pengguna berisiko tidak terdeteksi.

8.3 Fitur Aplikasi yang Berhasil Diimplementasi

Tabel 14. Fitur Aplikasi

Fitur	Status	Keterangan
Dashboard Streamlit	Selesai	Menampilkan insight DS
ML Service FastAPI	Selesai	Endpoint prediksi
Skrining Dasar	Selesai	7 fitur utama
Skrining Komprehensif	Selesai	16 fitur lengkap
Penjelasan Risiko	Selesai	Gemini API / fallback
Autentikasi Supabase	Selesai	Login/register

Riwayat Skrining	Selesai	Histori user
Reminder Skrining	Selesai	Pengingat berkala
Disclaimer Medis	Selesai	Responsible AI

8.4 Keterbatasan Sistem

Beberapa keterbatasan sistem adalah:

1. Generalisasi dataset.
Dataset berasal dari BRFSS 2015 Amerika Serikat sehingga pola risiko mungkin tidak sepenuhnya merepresentasikan populasi Indonesia.
2. Tidak menggunakan fitur laboratorium.
Model tidak menggunakan data objektif seperti gula darah puasa, HbA1c, atau hasil pemeriksaan klinis.
3. Bukan diagnosis medis.
Sistem hanya memberikan estimasi risiko awal dan tidak menggantikan pemeriksaan dokter.
4. Data bersifat self-report.
Beberapa variabel bergantung pada jawaban responden sehingga berpotensi memiliki bias pelaporan.
5. Temporal dataset.
Data berasal dari tahun 2015 sehingga pola kesehatan masyarakat mungkin telah berubah.

BAB 9

KESIMPULAN & REKOMENDASI

9.1 Kesimpulan

Proyek DiabeSense berhasil mengembangkan sistem skrining risiko diabetes personal berbasis machine learning. Tim Data Science berhasil membangun pipeline analisis lengkap mulai dari data gathering, data assessment, data cleaning, EDA, feature engineering, hingga dashboard interaktif. Hasil analisis menunjukkan bahwa faktor klinis seperti GenHlth, HighBP, BMI, HighChol, dan Age memiliki hubungan kuat terhadap diabetes. Selain itu, metabolic risk score menjadi fitur komposit yang menunjukkan hubungan sangat kuat dengan prevalensi diabetes.

Tim AI Engineer mengembangkan model MLP untuk prediksi risiko diabetes dengan prioritas pada recall kelas positif. Model kemudian disajikan melalui FastAPI ML Service sehingga dapat digunakan oleh aplikasi web. Tim Full Stack mengembangkan web application yang memungkinkan pengguna melakukan skrining dasar maupun komprehensif, melihat hasil risiko, memperoleh penjelasan, serta mengakses fitur tambahan seperti riwayat dan reminder.

Secara keseluruhan, DiabeSense berhasil mengintegrasikan data science, machine learning, dan full stack development menjadi sistem skrining risiko diabetes yang dapat digunakan sebagai alat bantu edukasi dan deteksi awal.

9.2 Rekomendasi Pengembangan

Rekomendasi pengembangan ke depan meliputi:

1. Melakukan validasi model menggunakan data populasi Indonesia seperti Riskesdas, SKI, atau data layanan kesehatan lokal.
2. Menambahkan fitur laboratorium seperti gula darah puasa, HbA1c, dan riwayat keluarga.
3. Melakukan retraining model secara berkala dengan data terbaru.
4. Mengembangkan sistem notifikasi push untuk reminder skrining.
5. Melakukan A/B testing untuk mengukur efektivitas penjelasan risiko berbasis AI.
6. Melakukan evaluasi usability kepada pengguna umum.
7. Menambahkan fitur rekomendasi personal berbasis profil risiko pengguna.

DAFTAR PUSTAKA

CDC. (2015). Behavioral Risk Factor Surveillance System. Centers for Disease Control and Prevention.

International Diabetes Federation. (2024). Diabetes Atlas: Indonesia Country Report.

Kementerian Kesehatan Republik Indonesia. (2023). Survei Kesehatan Indonesia 2023.

World Health Organization. (2024). Diabetes Fact Sheet.

TensorFlow. (n.d.). Keras documentation.

FastAPI. (n.d.). FastAPI documentation.

Next.js. (n.d.). Next.js documentation.

Supabase. (n.d.). Supabase documentation.

Streamlit. (n.d.). Streamlit documentation

LAMPIRAN

Lampiran Ringkasan Metrik EDA

Business Question	Temuan Utama	Angka Kunci
Q1: Faktor Risiko	GenHlth menjadi fitur dengan korelasi tertinggi	$r = 0,4076$
Q2: Gaya Hidup	Lifestyle risk meningkat	Score 0–3
Q3: Usia & BMI	Risiko naik dengan usia dan BMI	~5% hingga >75%
Q4: Komorbiditas	Akumulasi risiko sangat kuat	19,09% hingga 84,02%
Q5: Sosial-Ekonomi	Gap income rendah vs tinggi	65,99% vs 34,85%